

lianxh.cn

基于 Lasso 的因果推断

连玉君 (中山大学)

arlionn@163.com



1. 何谓 Lasso ?

- 稀疏性
- 过拟合问题
- 预测偏差 v.s 预测方差

何谓 Lasso ?

- **Lasso:** Least Absolute Shrinkage and Selection Operator, Tibshirani (1996)
- **用途:** 预测、模型筛选
- **核心思想:** 对传统回归模型施加约束 (惩罚项), 滤除次要变量, 选出精简模型
 - 配合交叉验证等手段来选择参数, Lasso 出的模型样本外预测能力 (泛化能力)
- 以 Lasso 为首的一系列方法 被通称为 “惩罚回归” (Penalized Regressions)。

稀疏性和近似稀疏性

Source: Abadie et al. (2010, JASA), 加州禁烟的政策效果, Figure 1






Table 2. State weights in the synthetic California


State	Weight	State	Weight
Alabama	0	Montana	0.199
Alaska	–	Nebraska	0
Arizona	–	Nevada	0.234
Arkansas	0	New Hampshire	0
Colorado	0.164	New Jersey	–
Connecticut	0.069	New Mexico	0
Delaware	0	New York	–
District of Columbia	–	North Carolina	0
Florida	–	North Dakota	0
Georgia	0	Ohio	0
Hawaii	–	Oklahoma	0
Idaho	0	Oregon	–
Illinois	0	Pennsylvania	0
Indiana	0	Rhode Island	0
Iowa	0	South Carolina	0
Kansas	0	South Dakota	0
Kentucky	0	Tennessee	0
Louisiana	0	Texas	0
Maine	0	Utah	0.334
Maryland	–	Vermont	0
Massachusetts	–	Virginia	0
Michigan	–	Washington	–
Minnesota	0	West Virginia	0
Mississippi	0	Wisconsin	0
Missouri	0	Wyoming	0

Source:
Abadie et al. (2010, JASA)


过拟合问题: 例 1




过拟合问题：例 2



过拟合问题：例 2





预测偏差 v.s 预测方差

<center>



预测「偏差-方差」的权衡

均方误差 (mean-square error, MSE):

$$\text{MSE}(\hat{\theta}) = \text{E}(\hat{\theta} - \theta_0)^2$$

- 待估参数为 θ , 其真实值为 θ_0 , 估计值为 $\hat{\theta}$,

估计量的 **方差**:

$$\text{Var}(\hat{\theta}) = \text{E}[\hat{\theta} - \text{E}(\hat{\theta})]^2$$

估计量的 **偏差**:


$$\text{Bias}(\hat{\theta}) = \text{E}(\hat{\theta}) - \theta_0$$

权衡关系:

$$\text{MSE}(\hat{\theta}) = \text{Bias}(\hat{\theta})^2 + \text{Var}(\hat{\theta})$$

预测「偏差-方差」的权衡

<center>



<center>




图 12-3 方差与偏差的权衡

2. 惩罚回归：核心思想

- 损失函数
- 范数与距离
- 惩罚回归

损失函数

考虑线性模型: $y_i = \mathbf{x}_i' \boldsymbol{\beta} + e_i, \quad i = 1, 2, \dots, n$

- y_i 是被解释变量 (在机器学习或统计学习中常被称为 "标签"),
- $\mathbf{x}_i$ 是一组解释变量构成的向量, $\boldsymbol{\beta}$ 为系数向量。

若采用 OLS, 则可以通过极小化残差平方和来估计参数,

$$\text{RSS}(\boldsymbol{\beta}) = \sum_{i=1}^n (y_i - \mathbf{x}_i' \boldsymbol{\beta})^2 = \sum_{i=1}^n e_i^2$$

在机器学习中, 上式被称为「**损失函数**」(loss function) 或「**代价函数**」(cost function)。

范数与距离：引入

采用矩阵方式, 线性回归模型通常写做: $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$

其中, $\mathbf{e} = (e_1, e_2, \dots, e_n)'$ 为干扰项向量。损失函数可以表示为:

$$L(\boldsymbol{\beta}) = \frac{1}{2n} \sum_{i=1}^n e_i^2 \quad \Longleftrightarrow \quad L(\boldsymbol{\beta}) = \frac{1}{2n} \|\mathbf{e}\|_2^2$$

或

$$L(\boldsymbol{\beta}) = \frac{1}{2n} \sum_{i=1}^n (y_i - \mathbf{x}_i' \boldsymbol{\beta})^2 \quad \Longleftrightarrow \quad L(\boldsymbol{\beta}) = \frac{1}{2n} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|_2^2$$

定义:

$$\|\mathbf{e}\|_2^2 = e_1^2 + e_2^2 + \dots + e_n^2$$

范数与距离:

给定向量 $\mathbf{x}$, 其范数的通用定义公式如下:

$$\|\mathbf{x}\|_p = (|x_1|^p + \dots + |x_n|^p)^{\frac{1}{p}} \quad p \geq 1, x \in \mathbb{R}^n$$

- ℓ_1 范数 ($p = 1$): $\|\mathbf{x}\|_1 = \sum_{i=1}^N |x_i|$.
 - 即向量各个元素的绝对值之和, 又称为「曼哈顿距离」
 - 使用 ℓ_1 范数可以度量两个向量间的差异 (绝对误差和)。
- ℓ_2 范数 ($p = 2$): $\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^N x_i^2}$,
 - 亦称 Euclid 范数 (欧几里得范数)。
 - 即向量各元素的平方和再开方, 也可以表示向量的长度 (模) 或两个向量之间的距离, 又称为「欧氏距离」。

惩罚回归：回顾 AIC 和 BIC

$$\text{AIC} = n \ln(RSS/n) + 2k$$

$$\text{BIC} = n \ln(RSS/n) + k \ln(n)$$

- 其中， n 为观察值个数， RSS 为残差平方和。

AIC 和 BIC 都试图在「拟合程度」和「模型复杂度」之间进行权衡，通用表达式为：

$$IC = n \ln(RSS/n) + c(n, K)$$

- 拟合程度：用 $n \ln(RSS/n)$ 来衡量，值越小越好 (拟合的好)
- 模型复杂度：用 (正数项) 来衡量，差别在于惩罚力度不同。
 - AIC: $c = 2K$
 - BIC: $c = K \log(n)$
- 对于一笔相同的数据， IC 值越小的模型越佳。

惩罚回归的目标函数

让损失函数 (Loss) 最小化不是最终目标, 需要加入描述模型复杂度的惩罚项, 极小化:

$$\text{Loss} + \lambda \Omega(f)$$

- Loss 为损失函数; $\Omega(f)$ 称为「正则化项」, λ 为调节参数。
- 所谓正则化项, 描述的其实是模型的复杂度, 它越高, 过拟合的风险也就越大。

🐱 在很多情况下, 无偏性并不是我们关注的重点, 但需要兼顾

3. Lasso 回归

- Lasso 的目标函数
- Lasso 的直观解释
- Lasso 估计与求解

3.1 Lasso: 目标函数

$$\min_{\beta_0, \beta} \left\{ \frac{1}{2N} \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 \right\}$$
$$\text{subject to } \sum_{j=1}^p |\beta_j| \leq \tau$$

约束条件 $\sum_{j=1}^p |\beta_j| \leq \tau$ 可以用 ℓ_1 范数表示为: $\|\boldsymbol{\beta}\|_1 \leq \tau$ 。矩阵形式:

$$\min_{\beta_0, \beta} \left\{ \frac{1}{2N} \|\mathbf{y} - \beta_0 \mathbf{1} - \mathbf{X}\boldsymbol{\beta}\|_2^2 \right\} \quad (1)$$
$$\text{subject to } \|\boldsymbol{\beta}\|_1 \leq \tau,$$

Lasso: 目标函数


将 (1) 式写成如下拉格朗日 (Lagrangian) 形式更易于求解:

$$\min_{\beta} \left\{ \frac{1}{2N} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \left(\sum_{j=1}^p |\beta_j| - \tau \right) \right\} \quad (2)$$


- 其中, $\lambda \geq 0$, 通常称为 “调节参数”。
- 由于 λ 与 τ 的乘积 $\lambda\tau$ 是一个常数, 因此, (1) 与 (2) 的极小化问题是等价的,


$$\min_{\beta} \left\{ \frac{1}{2N} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_1 \right\} \quad (3)$$


3.2 Lasso 的直观解释




OLS 系数与 RSS









3.3 Lasso: 估计

Lasso 的估计

多数情况下, 必须通过数值方法求解 Lasso, 如最小角回归法 (LARS), 坐标下降法等。

Lasso 估计可以通过极小化如下目标函数得到:

$$\min_{\beta} \text{RSS}_1(\beta, \lambda) = \left\{ \frac{1}{2N} \sum_{i=1}^N (y_i - \mathbf{x}_1\beta_1 \cdots - \mathbf{x}_p\beta_p)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}$$

一阶条件为:

$$\frac{\partial \text{RSS}_1(\beta, \lambda)}{\partial \beta_j} = \mathbf{X}'_j(\mathbf{y} - \mathbf{X}\beta) + \lambda \text{sgn}(\beta_j) = 0$$

其中, $\mathbf{X} = (\mathbf{x}_1, \mathbf{x}_2, \cdots, \mathbf{x}_k)$, $\beta = (\beta_1, \beta_2, \cdots, \beta_p)'$ 。



$$\frac{\partial \text{RSS}_1(\boldsymbol{\beta}, \lambda)}{\partial \beta_j} = \mathbf{X}'_j(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) + \lambda \text{sgn}(\beta_j) = 0$$

$\text{sgn}()$ 为 “符号函数”, 用于记录变量 z 的符号:

$$\text{sgn}(z) = \begin{cases} -1 & z < 0 \\ +1 & z > 0 \\ 0 & z = 0 \end{cases}$$

次导数

- $f(x) = |x|$ 在 $x = 0$ 处的次导数不再是一个特定的数值,
- 而是一个非空闭区间: $[-1, +1]$,
- 取值范围由 $f(x)$ 在 $x = 0$ 左侧和右侧的偏导数确定。



次导数

这从次导数的标记符号可以看出： $\partial f(x) = \{\nabla f(x)\}$ 。

同时, 在 $x = 0$ 两侧, 都满足 $f(x) \geq f(0)$ 。

基于上述介绍可知:

$$\lambda \frac{\partial |\beta_j|}{\partial \beta_j} = \lambda \operatorname{sgn}(\beta_j) = \begin{cases} -\lambda & \beta_j < 0 \\ [-\lambda, \lambda] & \beta_j = 0 \\ \lambda & \beta_j > 0 \end{cases}$$

由此可以看出调节参数 λ 的作用, 它可以控制右图的开合状态, 从而决定当 $\beta_j = 0$ 时惩罚的力度。

特例：Lasso 的解析解

若变换 $\mathbf{X}$ 矩阵使所有解释变量都彼此正交, 即 $\mathbf{X}'\mathbf{X} = \mathbf{I}_p$, 则 Lasso 存在解析解。


此时, 一阶条件可以简化为:

$$\hat{\beta}_{\text{Lasso},j} - \hat{\beta}_{\text{ols},j} + \lambda \operatorname{sgn}(\hat{\beta}_{\text{Lasso},j}) = 0$$

由此解得 (这里省略了下标 j):

$$\hat{\beta}_{\text{Lasso},j} = \begin{cases} \hat{\beta}_{\text{OLS}} - \lambda & \hat{\beta}_{\text{OLS}} > \lambda \\ 0 & |\hat{\beta}_{\text{OLS}}| \leq \lambda \\ \hat{\beta}_{\text{OLS}} + \lambda & \hat{\beta}_{\text{OLS}} < -\lambda \end{cases}$$

可见, Lasso 估计是 OLS 估计的连续函数。当 OLS 系数的绝对值小于 λ 时, Lasso 估计值被强制设定为 0 (这就是所谓的变量筛选功能), 而其它系数则被统一向零收缩 λ 。



4. 岭回归 (Ridge Regression)


4.1 岭回归：目标函数


岭回归是在 OLS 基础上对系数施以 ℓ_2 范数的约束得到的, 目标函数为:

$$\begin{aligned} \underset{\beta_0, \beta}{\text{minimize}} \quad & \left\{ \frac{1}{2N} \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 \right\} \\ \text{subject to} \quad & \sum_{j=1}^p \beta_j^2 \leq \tau^2 \end{aligned}$$


其中, $\tau > 0$ 是收缩参数。用矩阵表示如下:

$$\min_{\beta} \left\{ \frac{1}{2N} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_2^2 \right\},$$







4.2 OLS, Lasso 和岭回归的系数关系



Lasso /岭回归系数与调节参数 (λ) 之间的关系



4.3 岭回归如何降低共线性?

$$\min_{\beta} \left\{ \frac{1}{2N} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_2^2 \right\},$$

上式的一阶条件为: $-2\mathbf{X}'(\mathbf{y} - \mathbf{X}\beta) + 2\lambda\beta = 0$

可推导出岭回归的估计量 $\hat{\beta}_{\text{ridge}}$ 为:

$$\hat{\beta}_{\text{ridge}} = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}_p)^{-1} \mathbf{X}'\mathbf{y}$$

- 当 p 很大时, $\mathbf{X}'\mathbf{X}$ 为病态矩阵, 致使 OLS 估计在数值上很不可靠。但上式则不同: 即使 $p > n$, 岭回归估计量仍然有唯一解。
- 具体而言, ℓ_2 范数惩罚项的加入可以让 $(\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})$ 满秩, 保证了可逆。
- 坏处: 系数估计有偏, 即 $E[\hat{\beta}_{\text{ridge}}] \neq \beta$ 。因此, 岭回归以放弃无偏性、降低精度为代价来解决病态矩阵问题。
- 单位矩阵 $\mathbf{I}$ 的对角线上全是 1, 像一条山岭一样, “岭回归”也因此得名。

5. 调节参数 λ 的选择

- 基本规则和流程
- 基于信息准则
- 基于交叉验证
- 基于经验法则

5.1 调节参数 λ 的选择：基本经验规则和流程

在惩罚回归中, 系数估计和变量筛选 (模型设定) 都取决于调节参数 λ 。

确定最优值 λ^* 的方法主要分为三类:

1. **信息准则 (IC)**: 选择最小化信息准则 AIC, AICc, BIC 或 EBIC 的 λ 的值。
2. **交叉验证 (CV)**: 它属于数据驱动方法, 更为关注模型的 样本外预测能力, 所需的假设条件较为宽松, 在样本量较大时尤为适用。
3. **理论推演 (plugin)**: 在一些常规的假设条件下, 推导出 理论上的 λ^* 值, 因此不必再执行 CV 和 IC 方法的搜索 过程, 颇为省时。此法更倾向于选出精简的模型。它是 Stata 中 Lasso 系列命令的标配, 也被外部命令 rlasso 所采用 (Arhens et al., 2020)。

选择依据

- 以样本外预测为目标时, 应选择以交叉验证为基础的方法,
 - 如下文介绍的 CV 和 adaptive-CV;
 - 适用场景举例: 时间安慰剂检验、违约率预测等
- 以变量筛选为目标时, 可以选择理论推演值 (plugin) 或信息准则 (如 BIC),
 - 前者速度极快, 后者在稀疏性较强的情况下表现稳定。
 - 适用场景举例: Controls 筛选; IVs 筛选

5.2 λ^* 的选择: 基于 BIC 准则

λ^* 的选择流程：基于 BIC 准则 —— 以岭回归为例

这里先以形式相对简单的岭回归估计量为例

$$\hat{\beta}_{\text{ridge}} = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}_p)^{-1}\mathbf{X}'\mathbf{y} \quad (1)$$

采用 BIC 准则作为模型评估标准, 确定 λ^* 的基本流程:

- Step 1: 预设未知参数 λ 的取值范围, 如 $\lambda_j \in \{0.01, 0.02, \dots, 8\}$, 相应的 j 标记为 $j = 1, 2 \dots J$.
- Step 2: 然后依次将 λ_j 带人 (1) 式, 计算出 BIC_j , 最终, $\{\text{BIC}_j\}$ 的最小值对应的 λ 便是其最优值 λ^* .

Note: 也可以用 AIC 等其他准则

信息准则 (1): AIC 和 BIC

简要回顾一下 AIC, BIC, HQIC 等信息准则的计算公式:

- AIC (Akaike Information Criterion): 赤池信息准则

$$\text{AIC} = -2 \ln(L) + 2k$$

- BIC (Bayesian Information Criterion): 贝叶斯信息准则

$$\text{BIC} = -2 \ln(L) + \ln(n)k$$

- 其中, $\ln(L)$ 是模型的对数似然函数值, n 是样本数, k 是模型的参数个数。
- 上述 IC 其实都是在 $\ln(L)$ 基础上施加惩罚后得到的。当 $n > 8$ 时, $\ln(n) > 2$, 因此, 多数情况下 BIC 对模型参数的惩罚都比 AIC 大, 更倾向于选择精简模型。

信息准则 (2): Lasso 情景下的 AIC 和 BIC

在 Lasso 情境中, AIC 和 BIC 可表示为:

$$\text{AIC}(\lambda) = n \ln \hat{\sigma}^2(\lambda) + 2 \text{df}(\lambda)$$

$$\text{BIC}(\lambda) = n \ln \hat{\sigma}^2(\lambda) + \text{df}(\lambda) \ln(n)$$

- 其中, $\hat{\sigma}^2(\lambda) = n^{-1} \sum_{i=1}^n \hat{\varepsilon}_i^2$ ($\hat{\varepsilon}_i$ 是残差),
- $\text{df}(\lambda)$ 是有效自由度, 用以衡量模型复杂程度, 可以用模型中非零系数的个数来代替
- AIC 和 BIC 都不太适合 "大 p 小 N " 型设定, 因为它们倾向于保留太多的变量。
- AIC_c 有助于克服 AIC 存在的小样本偏差, 因此, 在 n 很小或具有高维数据时, 应该优先使用 (Sugiura, 1978; Hurvich and Tsai, 1989)。

$$\text{AIC}_c(\lambda) = n \ln \hat{\sigma}^2(\lambda) + 2 \text{df}(\lambda) \frac{n}{n - \text{df}(\lambda)}$$


信息准则 (3): EBIC

- BIC 假设每个模型出现的概率相同。在我们对模型设定没有任何先验知识时, 该假设有其合理性, 但在高维情境下, BIC 也倾向于选人太多变量 (over-select)。
- 为此, Chen and Chen (2008) 提出了 EBIC (Extended BIC), 它对参数数量施加了更为严格的惩罚, 选出的模型更为精简, 当 $p > n$ 时效果更为明显。

$$\text{EBIC}_{\xi}(\lambda) = n \ln \hat{\sigma}^2(\lambda) + \text{df}(\lambda) \ln(n) + 2\xi \text{df}(\lambda) \ln(p)$$

- 其中, 参数 $\xi \in [0, 1]$ 用于控制惩罚力度。
- Chen and Chen (2008, p.768) 设定为 $\xi = 1 - \ln(n)/\{2 \ln(p)\}$ 。

5.3 λ^* 的选择: K 折交叉验证法 (k-fold CV) —— 以岭回归为例



$$\hat{\beta}_{\text{ridge}} = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}_p)^{-1}\mathbf{X}'\mathbf{y} \quad (1)$$

- **Step 1:** 预设未知参数 λ 的取值范围, 如 $\lambda_j \in \{0.01, 0.02, \dots, 8\}$, 标记为 $\{\lambda_1, \lambda_2 \dots \lambda_J\}$ 。
- **Step 2:** 针对 $\lambda_1 (j = 1)$, 计算 $CV_K(\lambda_1)$
 - 2a. 将样本随机等分为 K 份 (如, 5 份)
 - 2b. 用其中 $K - 1$ 份做岭回归, 剩下的第 k 份做样本外预测, 计算均方误差:

$$\text{MSE}_k = \frac{1}{n_k} \sum_{i \in G_k} (y_i - \hat{y}_i)^2$$

- 2c. 针对 $k = 2 \dots K$, 重复进行 2b, 得到 $\{\text{MSE}_k\} (k = 1, 2, \dots, K)$, 以及它们的均值 $\overline{\text{MSE}}(\lambda_1)$ 。

$$CV_K(\lambda_1) = \overline{\text{MSE}}(\lambda_1) = \sum_{k=1}^K \frac{n_k}{N} \text{MSE}_k$$


- Step 1: 预设未知参数 λ 的取值范围, 如 $\lambda_j \in \{0.01, 0.02, \dots, 8\}$, 标记为 $\{\lambda_1, \lambda_2 \dots \lambda_J\}$ 。
- Step 2: 针对 $\lambda_1 (j = 1)$, 计算 $CV_K(\lambda_1)$
- Step 3: 针对每一个 λ_j , 重复进行 Step 2, 得到 $CV_K(\lambda_j) (j = 1, 2, \dots, J)$ 。

最终, 所有 $CV_K(\lambda_j) (j = 1, 2, \dots, J)$ 的最小值对应的 λ 即为 λ^* 。


说明:

- 假设 $J = 100$, $K = 5$, 则上述过程需要经历 500 次运算。
- 实操中, $K = 10$ 折最常用;
- 上述 CV 过程, 也适用于 Lasso 等其他模型


10 fold CV 程序思路



10 fold CV: Stata 实例演示



10 fold CV: Stata 实例演示 (cont.)



5.4 λ^* 的选择：理论推演值-plugin

- plugin 是基于理论分析来确定 λ^* 的,
 - 参见 Belloni and Chernozhukov (2011), Belloni et al. (2012), and Belloni, Chernozhukov, and Wei (2016)。
- 相对于 CV 和 BIC, plugin 选出的变量都更少, 因此模型更精简。
- 若主要目标是模型筛选 (如后文介绍的 Lasso-IV, 或 Double Selection), plugin 是非常有效的方法。
- 最重要的是, 当样本较小时, 基于 CV 的方法会对随机分组非常敏感, 且经常因为无法找出合适的 λ 而导致程序中止。此时, plugin 就会非常奏效, 因为它给出的 λ^* 是从理论上直接推到出来的, 无需执行任何搜索程序。

6. Lasso 扩展模型

- 弹性网
- 平方根 Lasso
- 自适应 Lasso

6.1 弹性网



为何要用弹性网？

- 岭回归：压缩系数, 有效避免高度共线性导致的系数估计不稳定
 - 局限：没有变量筛选能力
- Lasso：压缩系数 + 变量筛选 —— 稀疏性假设 → 将部分变量的系数设为零
 - 局限：若模型中包含一组高度相关的变量, 则 Lasso 只能随机地选择其中的一个或几个, 而无法整体选入/删去。
- 弹性网 = 岭回归 + Lasso
 - 优点：一组高度相关的变量 —— 整体选入或剔除

弹性网：模型设定, Zou and Hastie (2005)

$$\underset{(\beta_0, \beta)}{\text{minimize}} \left\{ \frac{1}{2} \sum_{i=1}^N (y_i - \beta_0 - x'_i \beta)^2 + \lambda \left[\frac{1}{2} (1 - \alpha) \|\beta\|_2^2 + \alpha \|\beta\|_1 \right] \right\}$$

- 其中, $\alpha \in [0, 1]$ 是一个可变参数。
- 显然, Lasso 和岭回归都是弹性网 (ENet) 的特例:
 - 当 $\alpha = 1$ 时, ENet 退化成 Lasso;
 - 当 $\alpha = 0$ 时, 则变成了岭回归。
- 模型中的参数 α 和 β 可以采用 K 折交叉验证法来确定调节参数的最佳取值
- 求解过程与 Lasso 相似, 多用循环坐标下降法。



6.2 平方根 Lasso

- 简称 sqrt-Lasso
- Belloni, Chernozhukov and Wang (2011) 提出

目标函数

$$\text{普通 Lasso: } \frac{1}{2N} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}')' (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}') + \lambda \sum_{j=1}^p |\beta_j|$$

$$\text{sqrt-Lasso: } \sqrt{\frac{1}{N} (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}')' (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}')} + \frac{\lambda}{N} \sum_{j=1}^p |\beta_j|$$

- 这种设定可以让扰动项的标准差成为一个常数, 易于求解 λ 的理论最优值 λ^* 。
- 该值可以为双重 Lasso (double-selection)、偏出 Lasso (partialing-out methods) 等需要多次 Lasso 估计的方法提供 λ 的初始值, 提高求解效率。
- 因此, sqrtLasso 通常用于确定其他模型中的 λ^* , 很少单独使用。

6.3 自适应 Lasso

- Adaptive Lasso, 简称 ALasso
- Zou (2006)

ALasso 简介

- 适用：比传统 Lasso 更稀疏的模型。
- 方法：
 - 在传统 Lasso 估计的基础上做二次/多次惩罚处理，大力惩罚较小的系数
 - ALasso 选出的模型比传统 Lasso 更为精简。

ALasso 的目标函数为:

$$\underset{\beta \in \mathbb{R}^p}{\text{minimize}} \left\{ \frac{1}{2} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \sum_{j=1}^p w_j |\beta_j| \right\}$$
$$w_j = 1/|\tilde{\beta}_j|^\theta$$

- w_j 为二次惩罚因子, $\tilde{\beta}_j$ 是基于 Lasso 或 OLS (或单变量 OLS) 得到的初始估计值
- 显然, 对于变量 j , 初始系数 $\tilde{\beta}_j$ 越小, 其二次惩罚权重 w_j 就越大, 在后续筛选中被删去的可能性越大。
- 初始参数 $\tilde{\beta}_j$ 的获取方法:
 - 若 $p < N$, 则可以用 OLS 获取;
 - 若 $p \geq N$, 可以用传统 Lasso, 或单变量 OLS 估计。

7. Lasso 在经济金融中的应用

- Post-Lasso
- Lasso IV
- Double Selection Lasso (DSL)
- Partialing-out Lasso (PO-Lasso)
- Double/Debiased Machine Learning (DML)

简介

- Lasso 的优势是预测，而非模型筛选，但可以借助其预测能力辅助因果推断，如：
 - 估计反事实结果
 - 克服冗余工具变量问题
- 多数研究中，我们感兴趣的变量都很明确，通常只有 1-2 个。但为了排除混淆因素的影响，还需要在模型中设置很多控制变量 / 工具变量，此时便可用 Lasso 处理如下两种情况：
 - 选择控制变量，以解决遗漏变量偏误。
 - 选择工具变量，以解决冗余工具变量引起的弱工具变量问题。

7.1 Post-Lasso

Lasso 估计量 $\hat{\beta}_{\text{Lasso}}$ 在筛选变量的同时也对系数进行了收缩 (惩罚)。收缩会引入偏差。

Post-Lasso 估计：先用 Lasso 筛选变量, 进而对选出的变量集执行 OLS 估计。

- **第一步**, 用 Lasso 估计如下模型, 筛选出的具有非零系数的变量集记为 X_S :

$$Y = X'\beta + e$$

- **第二步**, 用被解释变量 Y 对 X_S 执行 OLS 估计, 得到系数估计值,

$$\hat{\beta}_S = (\mathbf{X}'_S \mathbf{X}_S)^{-1} (\mathbf{X}'_S \mathbf{Y})$$

可以看出, 所谓的 Post-Lasso, 本质上是借助 Lasso 进行变量筛选, 进而用 OLS 对选出的变量执行传统的线性回归。关键在于第一步的筛选过程是否能挑选出正确的模型。

Note: 根据需要, 第一步可以换用弹性网或自适应 Lasso 等方法, 以便保证变量筛选的一致性。

需要特别强调的是, Post-Lasso 这种估计思想的价值远比其自身的应用价值要高。若单独使用该方法进行因果推断或回归分析, 需要非常谨慎。原因有二:

- 其一, Post-Lasso 是两步估计法, 第一阶段的 Lasso 过程存在随机性 (λ 的选择具有随机性), 这种 "sample-to-sample variability" 导致的偏误需要在第二阶段的 OLS 回归中予以考虑, 比如, 采用纠偏后的标准误, 然而, 这并非易事。
- 其二, Lasso 会删去很多 "不重要 (系数较小)" 的变量, 或者在一组高度相关的变量中随机删除其中的一部分。
 - 若研究目的是预测, 这些处理不会产生太大的影响, 甚至是必须的,
 - 但对于模型筛选而言, 则会导致遗漏变量偏误。

7.2 Lasso IV

冗余工具变量问题

- 多数情况下, 我们都很难找到工具变量
- 但有时情况恰好相反: 我们有很多潜在的工具变量, 但它们具有稀疏性
 - 只有一小部分与内生变量存在较强的相关性, 其它的则都是“弱工具变量”。
- e.g., 在动态面板估计中, 若 T 较大, 比如 $T > 40$,
 - 则在使用 SYS-GMM 且不对工具变量的取舍做任何限制时, 往往会导致在一个只有 $NT = 30 \times 40 = 1200$ 个观察值的样本中, 被 Stata 的 xtabond2 或 xtdpdsys 自动选入的工具变量数超过 300 个。
 - 这会导致严重的自由度损耗, 也会导致后续的过度识别检验和序列相关检验无法通过 (意味着这些工具变量不全是“干净”的 IV)。
 - 为了应对这种情形, 我们会人为地限制工具变量个数, 但这又导致工具变量的主观选择, 致使实证结果存在一定的人为操控嫌疑。

Lasso-IV 估计量

Belloni, et al. (2012) 利用 Lasso 的变量筛选功能剔除冗余 IVs。

考虑如下基本的 IV 模型设定：

$$\begin{aligned} Y &= X'\beta + e, & \mathbf{E}[e \mid Z] &= 0 \\ X &= \Gamma'Z + U, & \mathbf{E}[U \mid Z] &= 0 \end{aligned}$$

- 其中, β 为 $k \times 1$ (固定), 而 Γ 为 $p \times n$ 。
- 关键: p 可以很大。
 - 如果 $p > n$, 则 2SLS 估计量与 OLS 估计等价。
 - 如果 $p < n$ 但较大, 则 2SLS 估计量存在 "冗余工具变量" 问题。
 - 此时, 可以用 Lasso: Belloni et al. (2012) 建议用 Lasso 或 Post-Lasso 估计 Γ 。

多个内生变量的情形

- 如果 X 中包含多个内生变量, 则可以依次执行 Lasso 筛选, 即让它们分别对 Z 进行 Lasso 回归。设第 j 个内生变量与工具变量之间的回归方程为:

$$X_j = \gamma_j' Z + U_j$$

Lasso 后的系数估计值为 $\hat{\gamma}_j (j = 1, 2, \dots, J)$ 。将这 J 个系数统一放置在矩阵 $\hat{\Gamma}_{\text{Lasso}}$ 中, 从而得到 X 的预测值 (类似于 2SLS 中第一阶段得到的拟合值):

$$\hat{\mathbf{X}}_{\text{Lasso}} = \mathbf{Z} \hat{\Gamma}_{\text{Lasso}}$$

最终, Lasso-IV 估计量可以表示为:

$$\hat{\beta}_{\text{Lasso-IV}} = \left(\hat{\mathbf{X}}_{\text{Lasso}}' \mathbf{X} \right)^{-1} \left(\hat{\mathbf{X}}_{\text{Lasso}}' \mathbf{Y} \right).$$

Lasso IV小结

- Lasso-IV 其实就是在传统的 2SLS 基础上增加了一个基于 Lasso 的变量筛选环节。
- 但这个看似简单的步骤却可以很好地解决困扰大家已久的「弱工具变量」问题。
- 例如, Belloni, Chernozhukov and Hansen (2014) 使用 Lasso-IV 方法重新估计了 Chen and Yeh (2012) 的模型后, 发现虽然备选工具变量有 144 个, 但采用 Lasso 筛选后真正有用的 IV 其实只有一个。
- 考虑到原文的样本中只有 185 个观察值, 将 IV 个数从 144 减少为 1 个, 估计值的有效性将大幅提高。

7.3 Double Selection Lasso (DSL)

- Belloni, Chernozhukov, and Hansen (2014b, RES)

Post-Lasso / Lasso-OLS 的局限

前面介绍的 Post-Lasso (或曰 Lasso-OLS 两步估计法) 虽然可以筛选变量, 但当模型策选目的是因果推断时, 该方法存在严重的缺陷。考虑如下模型:

$$Y = D\theta + X_1'\beta_1 + X_2'\beta_2 + e, \quad \mathbb{E}[e \mid D, X_1, X_2] = 0$$

- 变量 D 是重点关注的政策虚拟变量
- 控制变量集为 $X = (X_1, X_2)$, 其数量可能很庞大, 甚至超过样本数
- 假设采用 Lasso 对控制变量 X 进行筛选, 最终得到系数非零的变量集为 X_1

在第二阶段的 OLS 回归中, 估计如下模型 (Post-Lasso):

$$Y = D\tilde{\theta} + X_1'\gamma_1 + u, \quad u = X_2'\beta_2 + e$$

- 显然, 这里很可能存在遗漏变量偏误。因为, 如果 $\text{corr}(D, X_2) \neq 0$, 则意味着 $\text{corr}(D, u) \neq 0$, 并进而导致 $\tilde{\theta}$ 的 OLS 估计不再是 θ 的无偏估计。

Double Selection Lasso (DSL)

$$Y = D\theta + X_1'\beta_1 + X_2'\beta_2 + e, \quad X = (X_1, X_2)$$

- 基本思想：分别用 Y 和 D 对 X 执行 Lasso 回归, 并将两次筛选出的变量的 **并集** 作为最终的控制变量集 X_{DS} 。
- 最终, 用 Y 对 D 和 X_{DS} 执行 OLS 回归即可。

Belloni et al. (2014b) 的理论分析表明,

- 若 Y, D 与 X 之间都满足近似稀疏性假设 (模型可以用数量有限的一组变量来很好地近似), 则 Double-Selection Lasso 估计量 及其 t 值都渐进地服从正态分布。因此, 常规的统计推断方法仍然适用。
- 需要注意的是, 这些结论都是以 $N \rightarrow \infty$ 为前提的, 在有限样本下仍然可能存在较大的偏差。

DS-Lasso 估计过程：详解

考虑如下回归模型: Stata 手册 [\[LASSO\] dsregress](#) (p.6)

$$\mathbf{E}[y \mid \mathbf{d}, \mathbf{x}] = \mathbf{d}\boldsymbol{\alpha}' + \beta_0 + \mathbf{x}\boldsymbol{\beta}'$$

其中,

- $\mathbf{d}$ 中包含 J 个我们要重点研究的变量 (多数情况下 $J = 1$ 或只有 2-3 个)。
- $\mathbf{x}$ 中包含 p 个控制变量, p 可以很大, 甚至超过样本数 ($p \gg n$) 或可以随着样本数的增加而增加。
- 数据必须满足稀疏性或近似稀疏性假设, 即 $\boldsymbol{\beta}$ 中系数非零的变量数目非常有限。

DS-Lasso 的实现过程: 详解

1. 用 y 对 $\mathbf{x}$ 执行线性 Lasso 估计 (`lasso linear y x*`), 将选出的变量集记为 $\tilde{\mathbf{x}}_y$ 。
2. 对 $\mathbf{d}$ 中的每个变量 $d_j (j = 1, \dots, J)$ 依次执行 Lasso 变量筛选, 即, 用 d_j 对 $\mathbf{x}$ 进行 Lasso 回归, 选出的变量集记为 $\tilde{\mathbf{x}}_j$ 。
3. 将第一步和第二步中筛选出来的所有变量集取并集, 得到最终的控制变量集, 即
$$\hat{\mathbf{x}} = \{\tilde{\mathbf{x}}_1 \cup \tilde{\mathbf{x}}_1 \cdots \tilde{\mathbf{x}}_J \cup \tilde{\mathbf{x}}_y\}$$
4. 用 y 对 $\mathbf{d}$ 和 $\hat{\mathbf{x}}$ 执行线性回归, 对应的系数估计估计值记为 $\hat{\alpha}$ 和 $\hat{\beta}$ 。Stata 中默认 计算稳健性标准误, 即 `reg y d x_hat, vce(robust)`。

Note: 第 3 步之所以「取并集」, 是为了避免遗漏变量偏误。换言之, 无论是对 y 还是对 d_j 有影响的变量都应保留。这是 DS-Lasso 用以克服 Post-Lasso 局限的主要手段。



7.4 Partialing-out Lasso (PO-Lasso)


Partial out 与 FWL 定理

- FWL 定理由 Frisch and Waugh (1933) 和 Lovell (1963) 提出
 - 它阐释了 OLS 回归的一个重要性质，为理解多元回归的系数含义，高效地估计高维固定效应提供了一个重要的理论基础。
 - Davidson and MacKinnon (1993, 19-24) 以及 Davidson and MacKinnon (2004, PDF, pp. 62–75, Slides) 对此进行非常细致的介绍。
- 应用：
 - 在 Stata 中，`reghdfe` 等处理高维固定效应的命令基本原理便是 FWL 定理
 - 在 `ivreg2`, `lasso2` 等命令中经常出现的 `partial()` 选项也基于 FWL 定理
 - 用于可视化展示多元回归结果的部分回归图命令 `avplot`, `reganat`, `avciplot`, `avciplots`, `binscatter` 等也都基于 FWL 定理。

- **Stata 实操**

- Filoso, V., 2013, Regression Anatomy, *Stata Journal*, 13(1): 92–106. [-PDF-](#)
- 图示线性回归系数：Frisch-Waugh定理与部分回归图
- 多元回归系数：我们都解释错了？





$$Y = X_1\beta_1 + X_2\beta_2 + u \Leftrightarrow \tilde{Y} = \tilde{X}_1\beta_1 + v$$


```
reg Y X2
```

```
predict eY, res →  $\tilde{Y} = A + B$ 
```

```
reg X1 X2
```

```
predict eX1, res →  $\tilde{X}_1 = F + B$ 
```

```
reg eY eX1 → dis _b[eX1] =  $\hat{\beta}_1$  →  $B$ 
```

$$Y = X_1\beta_1 + X_2\beta_2 + u \Leftrightarrow Y = \tilde{X}_1\beta_1 + v$$

- 事实上, 只需从 X_1 中去除 (partial out) X_2 的影响, 得到 $\tilde{X}_1$, 进而用 Y 对 $\tilde{X}_1$ 进行回归即可。即, 如下回归都是等价的:
 - reg $\tilde{Y}$ on $\tilde{X}_1$
 - reg Y on $\tilde{X}_1$
 - reg Y on X_1, X_2

回顾与对比

DS-Lasso:

1. 用 Y 对 X 执行 Lasso 回归, 筛选出变量集 $\tilde{X}_1$;
2. 用 D 对 X 执行 Lasso 回归, 筛选出变量集 $\tilde{X}_2$;
3. 最终的控制变量集 $\tilde{X}_{DS} = \tilde{X}_1 \cup \tilde{X}_2$;
4. 用 Y 对 D 和 $\tilde{X}_{DS}$ 执行 OLS 回归。变量 D 的系数 $\hat{\theta}_{DS}$ 是 θ 的一致估计。

PO-Lasso: (NEW)

1. 用 Y 对 X 执行 Lasso 选出 $\tilde{X}_1$, 进而用 Y 对 $\tilde{X}_1$ 执行 OLS 回归, 得到残差 $\hat{E}_Y$;
2. 用 D 对 X 执行相同操作, 得到残差 $\hat{E}_D$;
3. 用 $\hat{E}_Y$ 对 $\hat{E}_D$ 执行 OLS, 则 $\hat{E}_D$ 的系数 $\hat{\theta}$ 是 θ 的一致估计

7.5 Double/Debiased Machine Learning (DDML)

DS-Lasso 和 PO-Lasso 的局限

- DS-Lasso 和 PO-Lasso 本质上都是 **两阶段估计**:
 - 第一阶段通过 Lasso 筛选变量 (模型筛选),
 - 第二阶段执行 OLS 或 IV 估计。
- **局限**:
 - 如果第一阶段的估计存在较大的偏差 (e.g. 有些重要变量未被选中), 这些偏差会进入第二阶段
 - 后果: 第二阶段的估计结果存在较大的偏差或方差。
- **解决办法**:
 - DML: 引入了交叉验证的思想 —— 最终的估计结果是 K 折估计的加权平均。
 - 可以视为: “模型均化” (Model Averaging)

我们要研究的目标模型与 DS-Lasso 以及 PO-Lasso 相同:

$$\begin{aligned} Y &= D\theta + X\beta + e \\ E[e \mid D, X] &= 0 \end{aligned} \quad (1)$$

相比于 PO-Lasso, DML 的主要改进在于:

- 增加了“样本拆分” (samplesplitting) 环节, 这可以降低 DS-Lasso 和 PO-Lasso 中两次 Lasso 之间的相关性,
- 防止第一阶段的偏误 **污染** 第二阶段的估计结果

模型设定

$$\begin{aligned} Y &= D\theta + X\beta + e \\ E[e \mid D, X] &= 0 \end{aligned} \quad (1)$$

为了便于说明其估计流程, 这里先增加一个辅助方程:


$$D = X'\gamma + V, \quad E[V \mid X] = 0 \quad (2)$$

把 (2) 带人 (1), 可得:

$$Y = X'\eta + U, \quad E[U \mid X] = 0 \quad (3)$$

其中, $\eta = \beta + \gamma\theta$, $U = e + V\theta$ 。

DML 引入了交叉验证的思想, 进行了所谓的 “K-折切分” (K-fold partitioning), 估计流程如下:



“K-折切分”估计

$$D = X' \gamma + V, \quad E[V | X] = 0 \quad (2)$$

$$Y = X' \eta + U, \quad E[U | X] = 0 \quad (3)$$

- S1: 去一折法 + Lasso, 得到 $\hat{U}$ 和 $\hat{V}$
- S2: 用 $\hat{U}$ 对 $\hat{V}$ 执行 OLS 估计, 得到

$$Y = D\theta + X\beta + e \quad (1)$$

中 θ 的一致估计, 即为 $\hat{\theta}_{\text{DML}}$

- S3: 计算 $\hat{\theta}_{\text{DML}}$ 的异方差稳健标准误, 进行统计推断, 与传统回归分析无异。

DML 的局限和建议

- **局限：** K 折分组是随机的 $\rightarrow$ 最终估计值随机 $\rightarrow$ 将 K 设置成较大的数值。问题：
 - 增加计算成本
 - N 不大时，过多的分组会导致参数估计的方差变大。
- **建议：**
 - DML 比较适合 N 较大的场景。
 - 测试不同 K 值下的结果，不应对 K 的选取敏感
 - 可行思路：循环交叉验证 —— 执行多次 (如 100 次) DML，取均值
- 上述过程也适用于 Logit, Poisson, IV 等估计方法

Stata 实操

DML 相关命令均以 `xpo` 开头, 包括:

- `xporegress` (线性回归), [\[LASSO\]](#) `xporegress`
- `xpologit` (Logit 模型), [\[LASSO\]](#) `xpologit`
- `xpopoisson` (泊松模型), [\[LASSO\]](#) `xpopoisson`
- `xpoivregress` (IV 估计), [\[LASSO\]](#) `xpoivregress`

<center>

实操和应用：参见 dofile

建议/纠错: arlionn@163.com